

CrackSAM-GeoLoRA




La géométrie apprise *dans* SAM 2 : protocole, contrôle causal, résultats

Louis HAUSEUX, Josiane ZERUBIA

Raphaël ANTOINE, Philippe FOUCHER, Pierre CHARBONNIER



Quatre itérations, un même verdict



La carte réellement injectée en juillet était `node_sim_max` : ni MST, ni composantes, ni centralité n'intervenaient. Le résultat négatif de la ligne CrackSAM ne condamne donc pas le Frangi généralisé complet.



La question de cette itération

Deux raisons de réessayer

- ▶ SAM 2 ne peut structurellement pas accéder à la **portée** ni au **thermique** ; aucune correction en aval ne créera cette information.
- ▶ Corriger une bande de **19 px** de large demande une représentation **multi-échelle** qu'une retouche de logits ne fournit pas.

Une raison d'en douter

Khánh Hà est **monomodal visible**, ses annotations sont **épaisses**, et la baseline est **supervisée sur ce domaine même**. La LoRA a peut-être déjà appris tout ce que la géométrie propose.

le protocole doit pouvoir réfuter l'hypothèse, pas seulement l'illustrer

Corpus

Khánh Hà : 9 121 train, 481 val, 1 695 test

Modèle

SAM 2 Hiera-L, LoRA $q/v \ r = 4$, 453 248 paramètres

Question

la géométrie ajoute-t-elle une information que la LoRA n'a pas déjà ?

Ce qu'on ajoute à la Frangi-similarité : onze canaux

Rôle	Canaux	Principe
Proposer	frangi_sim	le node_sim_max historique, 5 échelles — seule carte des essais précédents
Récuser une ombre	ofs, ofa, abs_energy	Oriented Flux Symmetry : tenseur de flux sur un disque, et antisymétrie sur l'anneau comme confiance [5]
Trancher ligne vs marche	even_odd, dbic, profile	réponse paire moins impaire ; sélection de modèle ΔBIC entre H_0 et H_1 ; deux flancs plus clairs au même rayon
Polarité sombre	phase_sym	Gabor en quadrature ; une marche est rejetée par odd [6]
Géométrie explicite	cos2 θ , sin2 θ , scale	orientation et rayon gagnant, bornés dans [0,1]

jamais multipliés entre eux


séparés jusqu'à l'encodeur

L'étude filtre-seul du 8 août montre pourquoi : la fusion *multiplicative* anti-ombre $\times$ Frangi retombe à environ 10 % de rétention quand la fissure passe sous l'ombre, contre 89,5 % pour OFS seul. Sur 24 paires ligne/marche, la fuite médiane d'OFS vaut 0,133 contre 1,000 pour la carte historique.




Les onze canaux sur une image réelle


Image




frangi_sim



ofs



phase_sym



bande épaisse, hors sujet

frangi_sim est accordé sur 19,1 px : il fusionne le réseau en une seule coulée.

presque vide

ofs s'abstient — ce qui est le comportement voulu, mais il ne propose alors plus rien.

saturé d'artefacts

phase_sym répond aux étoiles de Gabor autant qu'aux fissures.

cracktree200_6774, vérité terrain à 0,8 % de pixels. Les fissures y font 1 à 2 px : c'est le régime que le réaccordage sur la largeur *moyenne* a sur-corrigé.



Des échelles mesurées, pas héritées

Filtre	Paramètre
Frangi	$\sigma = \{1,5; 3; 5; 8; 12\}$
OFS	rayons $\{2, 3, 4, 6, 8\}$
Phase	$\lambda = \{5; 8; 12; 18\}$
Profil, ΔBIC	$\sigma = \{1,2; 2; 3; 4,5; 6\}$

L'évidence est calculée à **224 px** : une fissure de 19,1 px à 448 y fait 9,6 px, au centre de la plage validée. À 448, couvrir la même structure demanderait des noyaux de Gabor de 143×143 .

L'erreur que la moyenne a masquée


La largeur de **19,1 px** est une médiane de corpus. Les scènes cracktree200, GAPS384 et Rissbilder ont des vérités terrain à **0,4–0,8 %** de pixels : des fissures **fin**es. En réaccordant sur 19,1 px, on a sur-corrigé pour une partie du corpus.

une évidence multi-échelle, et non mono-largeur

Échelles gelées dans manifest_train.json : target_width_px = 9,55, 11 canaux, 9 605 caches d'évidence calculés (environ 19 s par image, sur CPU).



Comment la géométrie entre dans SAM 2



Les corrections sont *additives* et injectées à trois résolutions, parce que les corridors mono-échelle des essais précédents ne couvraient que 1,8 % de la vérité terrain contre 5,7 % attendus.



Le point selle qui a coûté une heure de GPU

Version fautive

$$dz = \gamma \cdot \text{proj}(x)$$

$$\gamma = 0 \text{ et } \text{proj} = 0$$

les *deux* gradients s'annulent



Version corrigée

$$\gamma = 1, \text{proj} = 0$$

$dz = 0$ à l'initialisation

et le gradient existe

constaté en réel

activation = 0,0000 après une époque complète, et la variante géométrique *numériquement identique* à sa version sans géométrie.

test de régression

test_adapter_gradients_are_not_both_dead_at_initialisation — l'un des 15 tests du module.

Trois autres incidents ont coûté du GPU sans changer les conclusions : un correctif transféré mais jamais extrait, deux entraînements concurrents sur le même GPU, et un pilote NVIDIA cassé par un changement de noyau. Le seul qui aurait pu *fausser* un résultat est le point selle.



Juger honnêtement : six exigences

Budget strictement égal	5 époques, graine 3407, même ordonnancement, même départ depuis la LoRA convergée. La baseline est réentraînée dans ces conditions : l'archivée valait 70 époques, elle n'est pas comparable.
Un facteur par barreau	clDice isole la perte de continuité ; geo y ajoute la géométrie ; to13 isole la tolérance <i>sans</i> clDice.
Un contrôle apparié	geo_to13_permuted : même capacité, même perte, même graine ; seul l' alignement image ↔ évidence est détruit. Sans lui, on ne sépare pas « la géométrie aide » de « les paramètres aident ».
Un test de nécessité d'entrée	à l'évaluation, evidence=None restitue la voie baseline bit à bit : si les scores ne bougent pas, l'adapter est décoratif.
Des deltas appariés par image	gains et pertes comptés séparément : une moyenne ne dit pas que 866 images sur 1 695 ont perdu.
La métrique choisie <i>avant</i>	deux conventions de tolérance ne classent pas pareil ; choisir après avoir vu les chiffres, c'est choisir son résultat.

ce qui manque : IC95 par bootstrap groupé, to15, et le contrôle permuté de la famille clDice

Exécution des 8–9 août 2026 sur RTX PRO 6000 Blackwell (97,9 Go). Chaque époque écrit un état complet, optimiseur compris : la reprise après préemption Spot repart à l'époque suivante.



L'échelle d'ablations

#	Variante	Perte	Évidence	Params	Ce qu'elle isole
0	baseline	CrackSAM	—	453 248	l'ancre à budget égal
1	cldice	+ soft-clDice	—	453 248	la continuité seule
2	geo	+ soft-clDice	alignée	744 049	la géométrie
3	tol3	+ tolérante $k=3$	—	453 248	la tolérance seule
4	geo_tol3	+ tolérante $k=3$	alignée	744 049	la géométrie, sans clDice
5	geo_tol3_permuted	+ tolérante $k=3$	d'une autre image	744 049	la capacité seule

Durée par variante
40–41 min

61 min pour geo

Coût de l'adapter
+1 min

744 049 contre 453 248 params

Époques
5

et non 20, l'optimum archivé

Les 21 minutes supplémentaires de geo viennent de soft-clDice, dont la squelettisation douce coûte dix passes de *pooling* par échantillon — et non de la géométrie.

L'loU stricte mesure surtout un biais de largeur

La vérité terrain contre elle-même

Perturbation du GT	IoU
dilaté de 1 px	0,881
érodé de 1 px	0,843
dilaté de 2 px	0,799

Un décalage d'un pixel coûte **douze points** d'IoU —
davantage que tous les écarts entre variantes mesurés ici.

Baseline : précision et rappel tolérants

k	0	1	2	3
Précision	0,759	0,888	0,923	0,941
Rappel	0,761	0,812	0,848	0,879

Un seul pixel de tolérance fait gagner +0,129 à la précision et
seulement +0,051 au rappel : l'essentiel de ce que l'IoU stricte
compte comme faux positifs est du **débordement de frontière**, pas
de la fausse détection.

comparer deux méthodes à $\pm 0,02$ d'IoU stricte revient largement à comparer leurs largeurs

Deux conventions de tolérance, deux classements

buffered — à privilégier

$$P_k = \frac{|P \cap \delta_k G|}{|P|}, \quad R_k = \frac{|G \cap \delta_k P|}{|G|}$$
$$\text{IoU}_k = \frac{F1_k}{2 - F1_k}$$

Ne dilate *jamais* les deux masques : mesure une distance d'appariement. Dilatation euclidienne, donc isotrope.

dilate_both — convention EUVIP du dépôt

$$\text{IoU}_k = \text{IoU}(\delta_k P, \delta_k G)$$


C'est `thicken(sk, 6)` puis Jaccard. Elle épaissit les deux masques, donc elle favorise les prédictions déjà larges, et sature vers 1.

$k = 8$	baseline	cldice	geo	tol3	geo_tol3	perm.
buffered	0,9213	0,9341	0,9347	0,9346	0,9374	0,9378
dilate_both	0,7720	0,8175	0,8181	0,7943	0,7960	0,7974

la même mesure à la même tolérance donne deux vainqueurs différents



Ce que la tolérance pardonne — et ce qu'elle ne pardonne pas



IoU tampon	$k=0$	$k=1$	$k=2$	$k=3$	$k=5$	$k=8$
prédiction parfaite	1,000	1,000	1,000	1,000	1,000	1,000
décalée de 2 px	0,200	0,500	1,000	1,000	1,000	1,000
deux fois trop large	0,429	0,714	1,000	1,000	1,000	1,000
rompue sur 4 px	0,917	0,958	1,000	1,000	1,000	1,000
rompue sur 20 px	0,583	0,625	0,667	0,708	0,792	0,917

l'IoU stricte sanctionne un décalage de 2 px (0,200) bien plus qu'une rupture de 20 px (0,583)

Ligne verticale de 3 px sur 48, dans une image de 64^2 ; scores recalculés par `scripts/05_tolerant_iou.py` lui-même. La tolérance est une distance d'appariement : elle efface donc aussi une rupture, mais seulement tant que celle-ci est plus courte que $2k$. Une coupure franche reste pénalisée à toutes les tolérances mesurées.

La perte tolérante, contrepartie différentiable

```
Gk = soft_dilate(G, k)
Pk = soft_dilate(P, k)
prec =  $\sum (P \cdot G_k) / \sum P$ 
rec =  $\sum (G \cdot P_k) / \sum G$ 
L = 1 - 2 prec · rec / (prec + rec)
```

max-pool

Même machinerie morphologique que `soft_skeleton`. La dilatation est *carrée* et non euclidienne : le rayon n'est pas une grandeur à estimer, c'est une tolérance choisie.

les variantes `tol*` n'incluent volontairement *pas* `clDice` : on isole la tolérance seule

Trois variantes ont été câblées dans le CLI d'entraînement : `tol3`, `tol5` et `geo_tol3`. `tol5` a été sacrifié pour faire place au contrôle causal, qui importait davantage : la sensibilité au rayon reste donc inconnue.

1 - F1 tolérant	k=0	k=1	k=3
parfait	0,0000	0,0000	0,0000
décalé de 2 px	0,6621	0,3310	0,0000
2× trop large	0,3983	0,1661	0,0000
rompu, 20 px	0,2609	0,2288	0,1694

le placement est pardonné, la rupture non



Les six barreaux, en IoU stricte

Variante	IoU	Précision	Rappel	Couv. sq.	Comp.	Sans évid.
baseline	0,6241	0,7588	0,7607	0,6792	2,76	—
cldice	0,6066	0,6738	0,8567	0,8254	2,65	—
geo	0,6083	0,6742	0,8590	0,8263	2,52	0,6138
tol3	0,6276	0,7400	0,7940	0,7238	3,31	—
geo_tol3	0,6270	0,7432	0,7869	0,7162	5,97	0,6281
geo_tol3_permuted	0,6265	0,7383	0,7925	0,7232	5,66	0,6281

Baseline à budget égal

0,6241

ancré, 5 époques

tol3

0,6276

+0,0035, sans géométrie

Contrôle permuté

0,6265

à 0,0005 de geo_tol3

Vérité terrain : 57,5 composantes connexes par image en moyenne, contre 2,5 à 6,0 pour les prédictions — toutes les variantes sous-segmentent massivement en *nombre* de composantes, y compris celles qui optimisent la continuité.

IoU tampon, six tolérances : le classement s'inverse

k	baseline	cldice	geo	tol3	geo_tol3	geo_tol3_perm.
0	0,6241	0,6066	0,6083	0,6276	0,6270	0,6265
1	0,7407	0,7574	0,7593	0,7586	0,7597	0,7601
2	0,7971	0,8213	0,8231	0,8186	0,8206	0,8214
3	0,8396	0,8659	0,8674	0,8607	0,8635	0,8644
5	0,8901	0,9110	0,9119	0,9072	0,9101	0,9108
8	0,9213	0,9341	0,9347	0,9346	0,9374	0,9378

à $k = 0$, tol3 gagne

Cesser de facturer une frontière que l'annotation ne définit pas **libère de la capacité utile**.

dès $k = 1$, tout dépasse la baseline

Le verdict « aucune variante ne bat la baseline » ne tenait qu'à tolérance nulle.
À $k = 3$: +0,0278 pour geo.

mais le contrôle mène 5 fois sur 6

geo_tol3_permuted est devant geo_tol3 à toutes les tolérances sauf $k = 0$.



Le contrôle qui tranche

k	tol3 — baseline	alignée — permutée
0	+0,0035	+0,0004
1	+0,0179	-0,0005
2	+0,0215	-0,0008
3	+0,0212	-0,0009
5	+0,0171	-0,0007
8	+0,0133	-0,0004

L'effet de la perte est **vingt à quarante fois** plus grand que l'écart entre géométrie alignée et géométrie d'une autre image.

aligner la géométrie sur l'image ne sert à rien

le déficit de geo_tol3 vient des 290 801 paramètres, pas d'un mauvais usage

Ce que le contrôle établit

L'adapter **s'active** : ses projections croissent jusqu'à $1,79 \times 10^{-3}$, et le test de nécessité d'entrée est positif (evidence=None change le score). Mais ce qu'il apprend **ne dépend pas** de la correspondance entre l'évidence et l'image.

Deltas appariés, par image

-0,0007

603 gains, 866 pertes, 226 nuls




Ce que la perte tolérante change, et ce qu'elle coûte


cracktree200_6774 — la baseline manque *intégralement* le réseau

0,000 → 0,219


Entrée




Vérité terrain



Baseline



Avec tol3



CRACK500_20160405_171336 — annotation épaisse (10,6 % des pixels)

0,875 → 0,510


Entrée




Vérité terrain



Baseline



Avec tol3



■ vrai positif ■ faux positif ■ manqué

Les gains se concentrent sur cracktree200, fissures fines et peu contrastées : le régime où exiger une frontière au pixel près est le plus coûteux et le moins pertinent. Les pertes se concentrent sur les annotations larges, où la tolérance autorise un débordement que l'IoU stricte sanctionne.




La famille cIDice : plus de rappel, moins de précision


cracktree200_6774 — le réseau fin est retrouvé

0,000 → 0,228


Entrée




Vérité terrain



Baseline



Avec geo



CFD_080 — le débordement autour d'une fissure déjà bien détectée

0,523 → 0,343


Entrée




Vérité terrain



Baseline



Avec geo



couverture du squelette : 0,679 → 0,826

précision : 0,759 → 0,674

C'est le même mécanisme dans les deux sens : `soft-cIDice` pousse à couvrir les squelettes, donc récupère les réseaux manqués et déborde là où la baseline était déjà juste. Ce que l'IoU stricte comptait comme faux positifs est en grande partie ce halo rouge.




Ce que la géométrie change

Rissbilder_for_Florian — le plus grand gain de la paire

0,153 → 0,405

Entrée




Vérité terrain



tol3




geo_tol3




GAPS384_0608 — la contrepartie, aussi fréquente

0,443 → 0,341


Entrée




Vérité terrain



tol3



geo_tol3




603 gains contre 866 pertes : les deux colonnes existent, en nombre comme en amplitude

Aucun de ces deux cas n'est atypique : la distribution des deltas appariés est un pic étroit centré sur zéro, avec une queue de part et d'autre.

Les deux plus grands gains, vus de bout en bout


CRACK500_20160405_171336

0,875 → 0,510 → 0,807



Rissbilder_for_Florian

0,422 → 0,153 → 0,405




la géométrie récupère ce que la tolérance avait coûté, et s'arrête juste avant la baseline

Ces deux images sont exactement les deux plus grandes *pertes* de tol3 face à la baseline ($-0,364$ et $-0,269$) et les deux plus grands *gains* de geo_tol3 face à tol3 ($+0,296$ et $+0,252$). Une galerie de gains construite sur ces deux images raconterait donc l'inverse de ce que dit le corpus.



Le piège de la galerie sélective



Les deux plus grands gains de geo_tol3	baseline	tol3	geo_tol3	Δ
CRACK500_20160405_171336	0,875	0,510	0,807	+0,296
Rissbilder_for_Florian	0,422	0,153	0,405	+0,252

ce sont exactement les deux plus grandes pertes de tol3

La géométrie ne fait que rendre ce que la perte tolérante avait coûté — et reste **sous la baseline** dans les deux cas.

et aucun canal ne désigne la fissure

Sur Rissbilder : frangi_sim est une tache sur le bord supérieur, ofa sature de coulures, phase_sym n'est qu'un entrelacs.

Le contrôle permuté obtient la *même* performance moyenne : il s'agit de variance d'entraînement, pas d'un effet de la géométrie. Une figure ne remplace pas un contrôle.

Trois conclusions fausses, corrigées par la mesure

« L'adapter coûte 2,5× plus cher »	Faux : c'était la contention entre deux entraînements concurrents sur le même GPU. Mesuré proprement, <code>geo_to13</code> prend 41 min contre 40 pour <code>to13</code> . Les 61 min de <code>geo</code> viennent de <code>soft-clDice</code> .
« <code>soft-clDice</code> dégrade »	Faux sous une métrique adaptée : $-0,0175$ en IoU stricte, $+0,0263$ à $k = 3$. Ce que l'IoU stricte comptait comme faux positifs était du débordement de frontière.
« Aucune variante ne bat la baseline »	Vrai à tolérance nulle <i>uniquement</i> . <code>to13</code> la bat même en strict ($+0,0035$), et toute la famille tolérante la dépasse dès $k = 1$.

trois fois, une conclusion tirée trop tôt d'une mesure inadaptée

le seul garde-fou qui a fonctionné : mesurer autrement, et exécuter le contrôle

- ✓ **Contrôle causal** : exécuté, `geo_tol3_permuted`. C'était la limite principale du rapport précédent.
- **Pas d'IC95** sur les écarts entre variantes : les deltas appariés sont calculés, le bootstrap groupé non. Plusieurs écarts sont du même ordre que la variance d'entraînement.
- **5 époques, pas 20**. Les variantes repartent d'un modèle convergé, mais l'optimum de validation de la baseline archivée est à l'époque 20.
- **`geo_permuted` et `geo_noise` non entraînés** : le $+0,0015$ de `geo` sur `cldice` n'est pas causalement attribué — même si le contrôle du triplet `tol3` rend une conclusion différente très improbable.
- **`tol5` non exécuté** : la sensibilité au rayon de tolérance reste inconnue.
- **Évidence mono-échelle**, accordée à une largeur moyenne peu représentative d'une partie du corpus.
- **Aucune évaluation multimodale**, ni sur ombres naturelles : l'argument central de la ligne n'est donc pas encore testé là où il pourrait tenir.

Action	Justification
1 Adopter la perte tolérante par défaut. to13 bat la baseline en strict et en tolérant, pour un coût nul.	gain acquis, reproductible
2 Trancher la métrique du projet. cIDice domine à $k \geq 1$ et en convention EUVIP ; to13 domine en strict.	les deux conventions ne classent pas pareil
3 Porter l'expérience en multimodal sur FIND. SAM 2 n'a pas accès à la portée : c'est le seul cadre où l'argument géométrique repose sur de l'information.	thèse de l'article ISPRS
4 Compléter les IC95 par bootstrap groupé, et le contrôle permuté de la famille cIDice.	plusieurs écarts sont dans le bruit

à ne pas faire : augmenter la capacité de l'adapter, allonger l'entraînement, empiler un GNN

Sur Khánh Hà — monomodal visible, annotations épaisses, baseline supervisée sur ce domaine même — le Frangi généralisé n'apporte **aucune** information que la LoRA n'ait déjà apprise. Ce n'est pas un signal faible mal exploité : c'est l'absence de signal.



Références

- [1] Kirillov et al., *Segment Anything*, ICCV 2023.
- [2] Ravi et al., *SAM 2 : Segment Anything in Images and Videos*, 2024.
- [3] Ge et al., *Fine-tuning vision foundation model for crack segmentation in civil infrastructures*, Construction and Building Materials, 2024.
- [4] Shit et al., *cIDice — a Novel Topology-Preserving Loss Function for Tubular Structure Segmentation*, CVPR 2021.
- [5] Law et Chung, *Three-dimensional curvilinear structure detection using optimally oriented flux*, ECCV 2008.
- [6] Kovesei, *Symmetry and asymmetry from local phase*, 1997.
- [7] Frangi et al., *Multiscale vessel enhancement filtering*, MICCAI 1998.
- [8] Hu et al., *LoRA : Low-Rank Adaptation of Large Language Models*, 2022.