

CrackSAM-GeoLoRA



Guider SAM 2 par la géométrie : comment, et pourquoi cela ne marche pas.

Louis HAUSEUX, Josiane ZERUBIA

Raphaël ANTOINE, Philippe FOUCHER, Pierre CHARBONNIER




Le corpus : Khánh Hà

Onze jeux publics réunis en un seul — routes, façades, murs. **9 121** images d'entraînement, **1 695** de test, dont 12 % sans aucune fissure.




Rissbilder

573




CRACK500

505



noncrack

212




Volker

148




DeepCrack

78




GAPS384

76



cracktree200

31



Sylvie Chambon

28



forest

18



CFD

18




Eugen Müller

8

Sous chaque vignette, son effectif de test.



Sa force : hors domaine, et sous flou




Khánh Hà, sous flou gaussien croissant

IoU	Khánh Hà	zéro-shot		
	flou fort	Road420	Facade390	Concrete3k
CrackSAM	0,492	0,622	0,454	0,680
SegFormer	0,444	0,582	0,462	0,653

CrackSAM s'en tire très bien : trois corpus jamais vus, et le flou.


Road420, en zéro-shot



GE et al., *Construction and Building Materials* 431:136573, 2024 — tableau 6 et figures. SegFormer est le meilleur des douze autres concurrents.



Une LoRA de rang 4



les poids de SAM 2
jamais modifiés


4 directions
les seules apprises

$$y = Wx + BAx, \quad \text{rang}(BA) \leq 4$$

$$B = 0 \implies y = Wx$$



Et seulement sur q et v



$$\text{Att}(X) = \text{softmax}\left(\frac{(XW_q)(XW_k)^T}{\sqrt{d}}\right) XW_v$$

$$W_q \leftarrow W_q + B_q A_q$$

$$W_v \leftarrow W_v + B_v A_v$$

W_k, W_o inchangés

SAM 2 Hiera-L

224,9 M

poids gelés

Appris

453 248

48 blocs, 7 attentions

Première tentative : la géométrie en mask_input



baseline = SAM 2 Hiera-L + LoRA q/v — + mask_input = la même, avec la Frangi-similarité injectée

Facade390 / DJ_Wall_231 — débordement : IoU 0,750 → 0,294




Road420 / IMG_6033 — effondrement, alors que la carte désigne la fissure : IoU 0,720 → 0,040



macro : 0,5675 → 0,5563

Pourquoi : une frontière d'ombre est une vallée, localement


Image



Vérité terrain




La carte injectée






L'idée : distinguer la vallée de la marche



fissure : vallée



ombre : marche


$$l_{x,\theta}(t) = l(x + t n_\theta), \quad n_\theta \perp \text{structure}, \theta \text{ donné par la Hessienne}$$

$$l_{x,\theta} = P + M : \quad P(t) = \frac{l_{x,\theta}(t) + l_{x,\theta}(-t)}{2} \quad M(t) = \frac{l_{x,\theta}(t) - l_{x,\theta}(-t)}{2}$$




Onze canaux, jamais multipliés


Image




frangi_sim




ofs



ofa



phase_sym



$$Q_r = \frac{1}{|\partial D_r|} \int_{D_r} \nabla^2 I \quad a_r = \frac{1}{|\partial D_r|} \oint_{\partial D_r} \nabla I$$


ofs = $\lambda_+(Q_r)$ ofa = $\|a_r\|$ vallée : λ_+ grand, $\|a_r\| \approx 0$; marche : $\|a_r\|$ grand

$$\text{phase_sym} = \max_{\theta} \frac{\sum_{\lambda} [-e_{\lambda\theta} - |o_{\lambda\theta}| - T]_+}{\sum_{\lambda} \sqrt{e_{\lambda\theta}^2 + o_{\lambda\theta}^2}}$$

(e, o) : paire de Gabor en quadrature — les mêmes P et M . — e : ligne *sombre*. — |o| : la marche est retranchée.



L'architecture : geo, contre la baseline



$$f_s \leftarrow f_s + \gamma P_s(E), \quad s \in \{32 \times 256^2, 64 \times 128^2, 256 \times 64^2\}$$

$$P_s \equiv 0 \text{ à } t = 0 \implies \text{geo} = \text{baseline}$$



La question, et la réponse

La question

E décrit la forme. SAM 2, non.
Peut-on la lui donner ?

La réponse : non

$|\text{IoU}(E) - \text{IoU}(E_\pi)| < 10^{-3}$
 E_π gagne **5 fois sur 6**

E : la géométrie de *son* image. E_π : celle d'une **autre** image. Par image : $-0,0007$, 603 gains, 866 pertes.



Le protocole : six barreaux, un contrôle

Variante	Perte	Évidence	Params	Isole
baseline	CrackSAM	—	453 248	l'ancre
cldice	+ cIDice	—	453 248	la continuité
geo	+ cIDice	alignée	744 049	la géométrie
tol3	+ tolérante 3 px	—	453 248	la tolérance
geo_tol3	+ tolérante 3 px	alignée	744 049	la géométrie
geo_tol3_permuted	+ tolérante 3 px	d'une autre image	744 049	le contrôle

Budget
5 époques
même graine, même ordre

Corpus
9 121 / 1 695
train / test

Durée
40–41 min
par variante

Le contrôle permuté a la même capacité et la même perte : seul l'appariement image ↔ évidence est détruit. Sans lui, on ne sépare pas la géométrie des paramètres ajoutés.



La géométrie n'aide pas

k	alignée	permutée	Δ
0	0,6270	0,6265	+0,0004
1	0,7597	0,7601	-0,0005
3	0,8635	0,8644	-0,0009
8	0,9374	0,9378	-0,0004

L'alignement ne sert à rien.




Image du *plus grand gain* de la géométrie : **aucun canal ne désigne la fissure.**

L'adapter s'active pourtant : projections jusqu'à $1,79 \times 10^{-3}$.

Le déficit résiduel de geo_tol3 face à tol3 vient des 290801 paramètres ajoutés, non d'un mauvais usage de la géométrie.



Et la galerie de gains trompe

CRACK500_20160405_171336

0,875 → 0,510 → 0,807


Image




Vérité terrain




Baseline



tol3



geo_tol3



Rissbilder_for_Florian

0,422 → 0,153 → 0,405


Image



Vérité terrain




Baseline



tol3



geo_tol3



La géométrie rend ce que la tolérance avait coûté, et reste sous la baseline.

■ vrai positif ■ faussement positif ■ faussement négatif (manqué)

Ces deux images sont les deux plus grands gains de la géométrie. Ce sont aussi les deux plus grandes pertes de tol3.

-
- 1 Arrêter le guidage géométrique sur Khánh Hà.
 - 2 Aller où l'information existe : **FIND multimodal** — portée et thermique, que SAM 2 n'a jamais vus.
 - 3 Choisir la métrique du projet : $k = 0$ et $k = 3$ ne donnent pas le même classement.
-

À ne pas faire : plus de capacité, plus d'époques, un GNN.


Limites : 5 époques, pas d'IC95, une seule échelle d'évidence.




La tolérance de 3 px : en quoi elle consiste

$$\Pr_k = \frac{|P \cap G^{\oplus k}|}{|P|} \quad Re_k = \frac{|G \cap P^{\oplus k}|}{|G|} \quad IoU_k = \frac{F_k}{2 - F_k}, \quad F_k = \frac{2 \Pr_k Re_k}{\Pr_k + Re_k}$$


parfait




décalé 2 px




2× trop large



rompu 4 px



rompu 20 px



IoU	strict	3 px
décalé de 2 px	0,200	1,000
2× trop large	0,429	1,000
rompu sur 4 px	0,917	1,000
rompu sur 20 px	0,583	0,708

$$IoU_0(G^{\oplus 1}, G) = \mathbf{0,881}$$

$$IoU_0(G^{\oplus 2}, G) = \mathbf{0,799}$$

Baseline, $k = 1$:

Pr : 0,759 → **0,888**

Re : 0,761 → 0,812

Un décalage de 2 px est plus puni qu'une rupture de 20 px.

baseline contre tol3 : ce que la tolérance gagne

cracktree200_6774 — réseau fin entièrement manqué



cracktree200_6243 — même régime : fines, peu contrastées



■ vrai positif ■ faussement positif ■ faussement négatif (manqué)

IoU tampon	strict	1 px	3 px	8 px
baseline	0,6241	0,7407	0,8396	0,9213
tol3	0,6276	0,7586	0,8607	0,9346

tol3 l'emporte à toutes les tolérances, y compris en strict. Les gains se concentrent sur cracktree200. Contrepartie mesurée : sur GAPS384_0552, le débordement coûte 0,517 à 0,308.