

CrackSAM-GeoLoRA



Guider SAM 2 par la géométrie : comment, et pourquoi cela ne marche pas.


Louis HAUSEUX, Josiane ZERUBIA

Raphaël ANTOINE, Philippe FOUCHER, Pierre CHARBONNIER




Le corpus : Khánh Hà


Onze jeux publics réunis en un seul — routes, façades, murs. **9 121** images d'entraînement, **1 695** de test, dont 12 % sans aucune fissure.




Rissbilder ∩ 573



CRACK500 ∩ 505




noncrack ∩ 212




Volker ∩ 148




DeepCrack ∩ 78



GAPS384 ∩ 76



cracktree200 ∩ 31



Sylvie Chambon ∩ 28



CFD ∩ 18

forest (18)
et *Eugen* (8)


non illustrés

Le nombre sous chaque vignette est l'effectif de test. Résolutions, éclairages et annotations hétérogènes.

Effectifs de test relevés dans `protocol/cracksam_paper/lists/lists_khanhha/test_vol.txt`, 1 695 au total. Le corpus n'étant pas versionné, chaque vignette est le panneau d'entrée d'une planche par cas archivée.




Sa force : le bruit, et le hors-domaine



IoU	flou fort	Road420	Facade390	Concrete3k
CrackSAM	0,492	0,622	0,454	0,680
SegFormer	0,444	0,582	0,462	0,653


Trois corpus jamais vus à l'entraînement. SegFormer est le meilleur des douze autres concurrents.

IoU sous flou gaussien croissant. Sur image nette les quatre modèles sont à 0,64 ; sous flou fort CrackSAM garde 0,46, les autres tombent sous 0,41.



Une ombre portée, en zéro-shot : c'est cette robustesse que la géométrie devait renforcer. — GE et al., « Fine-tuning vision foundation model for crack segmentation in civil infrastructures », *Construction and Building Materials* 431:136573, 2024 ; figures et tableau 6 du papier. « Flou fort » : image réduite de moitié, puis floutée. Notre baseline reprend la recette sur SAM 2 Hiera-L.

Une LoRA de rang 4




$$y = Wx + BAx$$

BA pèse **4 608** poids là où W en a **331 776**. Et $B = 0$ au départ : à l'initialisation, le modèle est SAM 2.

Exemple chiffré sur une projection 576×576 d'un bloc de Hiera-L.



Et seulement sur q et v



q : où l'on regarde. v : ce que l'on en retient. k et la sortie : intacts.

SAM 2 Hiera-L
224,9 M
poids gelés

Appris
453 248
48 blocs, 7 attentions

Soit
0,2 %
1,8 Mo à sauvegarder

Le qkv de Hiera est une projection fusionnée : la correction y est écrite sur les tranches q et v , celle de k restant nulle.

Première tentative : la géométrie en `mask_input`



Une **affinité locale** est présentée à SAM 2 comme une **hypothèse de segmentation déjà faite**.




Et pourtant l'alignement *est* lu : le prompt correct vaut +0,2473 contre un prompt permuté. L'information est là, l'encodage nuit.

Matrice causale du 20 juillet 2026. Le MST, les composantes et la centralité ne participaient pas : l'extracteur rendait `node_sim_max` avant eux.



Pourquoi : une frontière d'ombre est une vallée, localement


Image



Vérité terrain



La carte injectée



Une fissure fine à gauche, une ombre portée à droite. La carte répond sur l'**ombre**, que la vérité terrain ignore.

Une Hessienne locale ne voit pas « une grande région sombre ». Elle voit une transition étroite : fine, contrastée, allongée, orientée, cohérente sur une longue distance.

Tout est normalisé **par l'image** : maximum par échelle, candidats relatifs, fraction d'arêtes conservée. Une image sans fissure produit donc une structure forte *relativement à elle-même*.

Sylvie_Chambon_319, étude anti-ombre du 8 août 2026. Le panneau de droite est `node_sim_max`, exactement la carte qui était injectée.



L'idée : distinguer la vallée de la marche



fissure : vallée

profil pair



ombre : marche

profil impair

$$I(x) = \underbrace{P(x)}_{P(-x)=P(x)} + \underbrace{M(x)}_{M(-x)=-M(x)}$$


Tout profil transverse se décompose en une partie **paire** et une partie **impaire**. Une fissure met son énergie dans P , une ombre dans M . Chaque canal mesure cet écart à sa façon — et aucun n'est multiplié aux autres.

C'est la seule idée de l'évidence géométrique. Les onze canaux en sont onze mesures indépendantes, calculées à 224^2 pour des fissures de 19,1 px à 448^2 .




Onze canaux, jamais multipliés


Image




frangi_sim




ofs



ofa



phase_sym




Canal	Ce qu'il mesure
frangi_sim	la carte des essais précédents : elle <i>propose</i>
ofs	flux du gradient entrant dans un disque — fort sur une vallée
ofa	gradient moyen sur le cercle — non nul sur une <i>marche</i>
even_odd, profile	réponse paire moins réponse impaire ; deux flancs clairs exigés au même rayon
dbic	compare explicitement « ombre seule » et « ombre + ligne sombre »
phase_sym	Gabor en quadrature : polarité sombre
cos2θ, sin2θ,	orientation, largeur, confiance absolue
scale, abs_energy	

cracktree200_6774. ofa est le canal *anti*-ombre : c'est lui qui récusé ce que ofs propose.



L'architecture : geo, contre la baseline



L'évidence est **ajoutée** aux traits de SAM 2, à trois échelles : 32×256^2 , 64×128^2 , 256×64^2 . Jamais par `mask_input`.

Les projections partent de **zéro** : à l'initialisation la correction est nulle, et geo est la baseline, au bit près. Une seule chose les sépare : **290 801** paramètres et onze canaux.

L'invite dense de juillet coûtait $-0,0979$ d'IoU : cette interface reste un contrôle négatif, jamais un chemin d'entraînement.



La question, et la réponse

La question

Une fissure a une forme : fine, longue, continue.

Le Frangi généralisé la décrit. SAM 2, non.

Peut-on la lui donner ? Et si oui, **où** et **sous quelle forme** ?

Trois tentatives ont déjà échoué. Ici, la géométrie est apprise *dans* le modèle.

La réponse : non

On donne au modèle la géométrie de **son** image. Puis celle d'une **autre** image.

Les deux se valent, partout : $|\Delta| < 0,001$.

La mauvaise gagne **5 fois sur 6**.

Par image : $-0,0007$ en moyenne, 603 gains, 866 pertes.

Khánh Hà, monomodal visible. 8-9 août 2026, RTX PRO 6000 Blackwell. Le modèle ne voit pas la différence.



Le protocole : six barreaux, un contrôle

Variante	Perte	Évidence	Params	Isole
baseline	CrackSAM	—	453 248	l'ancre
cldice	+ cIDice	—	453 248	la continuité
geo	+ cIDice	alignée	744 049	la géométrie
tol3	+ tolérante 3 px	—	453 248	la tolérance
geo_tol3	+ tolérante 3 px	alignée	744 049	la géométrie
geo_tol3_permuted	+ tolérante 3 px	d'une autre image	744 049	le contrôle

Budget
5 époques
même graine, même ordre

Corpus
9 121 / 1 695
train / test

Durée
40–41 min
par variante

Le contrôle permuté a la même capacité et la même perte : seul l'appariement image ↔ évidence est détruit. Sans lui, on ne sépare pas la géométrie des paramètres ajoutés.

La géométrie n'aide pas

k	alignée	permutée	Δ
0	0,6270	0,6265	+0,0004
1	0,7597	0,7601	-0,0005
3	0,8635	0,8644	-0,0009
8	0,9374	0,9378	-0,0004

L'alignement ne sert à rien.




Image du *plus grand gain* de la géométrie : **aucun canal ne désigne la fissure.**

L'adapter s'active pourtant : projections jusqu'à $1,79 \times 10^{-3}$.

Le déficit résiduel de geo_tol3 face à tol3 vient des 290801 paramètres ajoutés, non d'un mauvais usage de la géométrie.



Et la galerie de gains trompe

CRACK500_20160405_171336

0,875 → 0,510 → 0,807


Image




Vérité terrain




Baseline



tol3



geo_tol3



Rissbilder_for_Florian

0,422 → 0,153 → 0,405


Image



Vérité terrain




Baseline



tol3



geo_tol3



La géométrie rend ce que la tolérance avait coûté, et reste sous la baseline.

■ vrai positif ■ faussement positif ■ faussement négatif (manqué)

Ces deux images sont les deux plus grands gains de la géométrie. Ce sont aussi les deux plus grandes pertes de tol3.

-
- 1 **Arrêter le guidage géométrique sur Khánh Hà.** Il n'y a pas un signal faible à mieux exploiter. Il n'y a pas de signal.
 - 2 **Aller là où l'information existe : FIND multimodal.** La portée et le thermique, SAM 2 ne les voit pas. Il n'a donc pas pu les apprendre.
 - 3 Choisir la métrique du projet. Deux conventions donnent deux classements.
-

À ne pas faire : plus de capacité, plus d'époques, un GNN.

Limites : 5 époques et non 20, pas d'IC95, une seule échelle d'évidence.


Sur ce corpus — monomodal visible, annotations épaisses, baseline supervisée sur le même domaine — le Frangi généralisé n'apporte aucune information que la LoRA n'ait déjà apprise.




La tolérance de 3 px : en quoi elle consiste

Un pixel prédit compte comme juste s'il tombe à moins de k pixels de la vérité terrain — et réciproquement. Une **distance d'appariement**, pas une dilatation.


parfait




décalé 2 px




2× trop large



rompu 4 px



rompu 20 px



IoU	strict	3 px
décalé de 2 px	0,200	1,000
2× trop large	0,429	1,000
rompu sur 4 px	0,917	1,000
rompu sur 20 px	0,583	0,708

La vérité terrain **dilatée d'un pixel** n'obtient plus que **0,881** contre elle-même, et **0,799** à deux pixels.





Baseline, à 1 px de tolérance : la précision passe de 0,759 à **0,888**, le rappel seulement de 0,761 à 0,812.

Un décalage de 2 px est plus puni qu'une rupture de 20 px.




La tolérance est une distance d'appariement : elle pardonne le placement et la largeur, et une rupture seulement si elle est plus courte que $2k$.

baseline contre tol3 : ce que la tolérance gagne

cracktree200_6774 — réseau fin entièrement manqué



cracktree200_6243 — même régime : fines, peu contrastées



■ vrai positif ■ faussement positif ■ faussement négatif (manqué)

IoU tampon	strict	1 px	3 px	8 px
baseline	0,6241	0,7407	0,8396	0,9213
tol3	0,6276	0,7586	0,8607	0,9346

tol3 l'emporte à toutes les tolérances, y compris en strict. Les gains se concentrent sur cracktree200. Contrepartie mesurée : sur GAPS384_0552, le débordement coûte 0,517 à 0,308.