




Comment guider l'attention *via* la hiérarchie ? Une idée à explorer



- L'**attention** : chaque jeton pose une **requête**, la compare aux **clefs** de tous les autres, et repart avec la moyenne de leurs **valeurs**, pondérée par un **score visuel** que SAM sait déjà calculer
- On y **ajoute un bonus** avant le *softmax* : un échange **favorisé**, jamais imposé [Graphormer 21]
- Le bonus vient de la **hiérarchie** du graphe de FRANGI : plus deux jetons **fusionnent tôt** dans l'arbre, plus il est fort, même loin dans l'image [EUVIP 26] ; LoRA l'apprend avec un **seul** coefficient β [LoRA 22]


$$\text{attention} = \text{softmax}(\text{scores visuels} + \beta B_H)$$

[Graphormer 21] C. Ying *et al.*, « Do Transformers really perform badly for graph representation ? », *NeurIPS*, 2021.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », *EUVIP*, 2026.

[LoRA 22] E. J. Hu *et al.*, « LoRA : low-rank adaptation of large language models », *ICLR*, 2022.

SAM gelé, LoRA et la hiérarchie : le montage



- **SAM reconnaît** les fissures et le fond : ses poids restent **gelés** [SAM 2 24]
- **L'arbre rapproche** deux morceaux d'une même fissure reliés par une chaîne de raccords compatibles, même loin dans l'image : le bonus B_H est d'autant plus fort que leur **fusion** dans le graphe de FRANGI est **précoce** [EUVIP 26] [MALIS 09]
- **LoRA apprend** avec ce **guidage**, pondéré par un **seul** coefficient β , parti de zéro [LoRA 22]

Objectif : moins de **ruptures**, pas plus de **faux raccords** — témoin : la simple proximité spatiale. **Rien n'est encore mesuré**

[SAM 2 24] N. Ravi *et al.*, « SAM 2 : segment anything in images and videos », 2024.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.

[MALIS 09] S. C. Turaga, K. L. Briggman, M. Helmstaedter, W. Denk, H. S. Seung, « Maximin affinity learning of image segmentation », NIPS, 2009.

[LoRA 22] E. J. Hu *et al.*, « LoRA : low-rank adaptation of large language models », ICLR, 2022.

Graphormer : ajouter une relation avant le softmax


$$A = \text{softmax} \left(\underbrace{QK^T / \sqrt{d_h}}_{\text{scores de contenu}} + \underbrace{B}_{\text{biais relationnel}} \right)$$

Dans Graphormer [Graphormer 21]

Distance de **plus court chemin** dans le graphe :

$$B_{ij} = b_{\phi(i,j)}.$$

Un nombre appris pour chaque distance.




Notre transposition vers SAM

Proximité issue des **hauteurs de fusion** du graphe de Frangi :

$$B = \beta B_H.$$

Une hiérarchie calculée ; un poids appris.




Principe repris : déplacer les scores *avant* leur normalisation. La hiérarchie Frangi et son insertion dans SAM sont **notre proposition**.

[Graphormer 21] C. Ying et al., « Do Transformers really perform badly for graph representation ? », *NeurIPS*, 2021.

Perspective : adapter le poids de la hiérarchie à l'image

Une motivation : les ombres




Image

Réponse Frangi

Exemple de nos essais : l'ombre attire Frangi.

Faire prédire un poids par les caractéristiques SAM



$$\beta(I) = \text{sigmoid}\left(w^\top \bar{h}(I) + b\right).$$

$\bar{h}(I)$: moyenne des caractéristiques **avant** l'attention guidée.

$$A_H(I) = \text{softmax}(\text{scores visuels} + \beta(I)B_H(I))$$

- **Hypothèse** : moins de guidage quand Frangi gêne, notamment dans les ombres ou la granularité. Poids appris avec LoRA par la perte de segmentation.
- **Test** : sans biais / β constant / $\beta(I)$. Comparer IoU, ruptures et faux raccords sur les mêmes images.

$B_H(I)$ dépend déjà de l'image ; on adapte ici **son poids**. Un poids global peut aussi réduire le guidage dans des zones utiles.