

Réunion Inria–Cerema




SAM gelé, LoRA et guidage hiérarchique

Inria, éq. AYANA : Louis HAUSEUX, Josiane ZERUBIA

Cerema, éq. ENDSUM : Raphaël ANTOINE, Philippe FOUCHER, Pierre CHARBONNIER

Hessienne, gradient : le guidage n'a pas aidé



Base : SAM gelé + LoRA [LoRA 22], comme dans CrackSAM [CrackSAM 24].


- Nos essais : ajouter la hessienne, le gradient ou Frangi **n'améliore pas** SAM + LoRA.
- Explication possible : ces informations locales semblent **déjà représentées par SAM**.
- Limite de Frangi : les ombres et la granularité provoquent des **sur-détections**.

Piste : relier les zones d'une même fissure par une hiérarchie.

[LoRA 22] E. J. Hu et al., « LoRA : low-rank adaptation of large language models », *ICLR*, 2022.

[CrackSAM 24] K. Ge et al., « Fine-tuning vision foundation model for crack segmentation in civil infrastructures », *Construction and Building Materials*, 2024.

Perspective : guider l'attention par la hiérarchie




- L'**attention** agrège les valeurs des autres jetons selon leurs **scores visuels**.
- On ajoute un **bias avant le softmax** [Graphormer 21].
- Dans la **hiérarchie Frangi**, une **fusion précoce** donne un biais plus fort, même entre zones éloignées dans l'image [EUVIP 26].

$$\text{attention} = \text{softmax}(\text{scores visuels} + \beta B_H)$$

[Graphormer 21] C. Ying et al., « Do Transformers really perform badly for graph representation ? », *NeurIPS*, 2021.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », *EUVIP*, 2026.

Perspective : SAM gelé + LoRA + hiérarchie



- ▶ **SAM** fournit les **caractéristiques visuelles** ; ses poids pré-entraînés restent **gelés** [SAM 2 24].
- ▶ L'**arbre** définit B_H : il rapproche les zones reliées par une chaîne de raccords compatibles [EUVIP 26].
- ▶ **LoRA** et le poids β sont **appris ensemble**, avec β initialisé à zéro [LoRA 22].

[SAM 2 24] N. Ravi *et al.*, « SAM 2 : segment anything in images and videos », 2024.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.

[LoRA 22] E. J. Hu *et al.*, « LoRA : low-rank adaptation of large language models », ICLR, 2022.

Graphormer : ajouter une relation avant le softmax

$$A = \text{softmax} \left(\underbrace{QK^\top / \sqrt{d_h}}_{\text{scores de contenu}} + \underbrace{B}_{\text{biais relationnel}} \right)$$

Dans Graphormer [Graphormer 21]

ϕ_{ij} : nombre minimal d'arêtes pour aller de i à j .

$$\phi_{ij} = \min_{\pi: i \rightsquigarrow j} |\pi|, \quad B_{ij} = b_{\phi_{ij}}.$$

$|\pi|$: nombre d'arêtes du chemin π .

$\phi_{ii} = 0$; $\phi_{ij} = -1$ si aucun chemin.



Chemins de 2 ou 3 arêtes : $\phi_{ij} = 2$, biais appris b_2 .


[Graphormer 21] C. Ying et al., « Do Transformers really perform badly for graph representation ? », *NeurIPS*, 2021.

Notre transposition vers SAM

Proximité issue des hauteurs de fusion du graphe de Frangi :

$$B = \beta B_H.$$

Une hiérarchie calculée ; un poids appris.




fusion précoce




Perspective : adapter le poids de la hiérarchie à l'image

Une motivation : les ombres




Image



Réponse Frangi

Exemple de nos essais : l'ombre attire Frangi.

Faire prédire un poids par les caractéristiques SAM



$$\beta(I) = \text{sigmoid}\left(w^\top \bar{h}(I) + b\right).$$

$\bar{h}(I)$: moyenne des caractéristiques **avant** l'attention guidée.

$$A_H(I) = \text{softmax}(\text{scores visuels} + \beta(I)B_H(I))$$

- **Hypothèse** : moins de guidage quand Frangi gêne, notamment dans les ombres ou la granularité. Poids appris avec LoRA par la perte de segmentation.
- **Test** : sans biais / β constant / $\beta(I)$. Comparer IoU, ruptures et faux raccords sur les mêmes images.

$B_H(I)$ dépend déjà de l'image ; on adapte ici **son poids**. Un poids global peut aussi réduire le guidage dans des zones utiles.